

## Razonamiento Basado en Probabilidades

## Medida de probabilidad

- **Definición 1. Medidas de Probabilidad.** Una función  $p$  que proyecta los sub-conjuntos de  $S \subseteq A$  en el intervalo  $[0, 1]$  se llama medida de la probabilidad si satisface los siguientes axiomas:

- **Axioma 1 (Normalización):**  $p(S) = 1$ .

- **Axioma 2 (Aditividad):** Para cualquier sucesión infinita  $A_1, A_2, \dots$  de subconjuntos disjuntos de  $S$ , se cumple la igualdad:

$$p\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} p(A_i)$$

- **Ejemplo probabilidades: Lanzamiento de un dado no trucado**

- $S = \{1, 2, 3, 4, 5, 6\}$

- $p(S) = 1$

- $p(\{1\}) = 1/6$

- $p(\{1, 3\}) = p(\{1\}) + p(\{3\}) = 1/3$ .

## Introducción

- **En la mayor parte de aplicaciones de S.E. la incertidumbre es lo común:**

- Por ejemplo, en un diagnóstico médico la pregunta típica es:

*Dado que el paciente presenta un conjunto de síntomas, ¿cuál de las enfermedades posibles es la que tiene el paciente?*

- Esta situación implica cierto grado de incertidumbre puesto que:

- Los hechos o datos pueden no ser conocidos con exactitud.

- Hay un cierto grado de incertidumbre en la información asociada a cada paciente (subjetividad, imprecisión, ausencia de información, errores, etc.) Por ejemplo, un paciente no está seguro de haber tenido fiebre la noche anterior.

- El conocimiento no es determinista.

- Las relaciones entre las enfermedades y los síntomas no son deterministas. Por ejemplo, podemos encontrar dos pacientes con los mismos síntomas y enfermedades diferentes.

## Distribución de probabilidad

- Sea  $\{X_1, \dots, X_n\}$  un conjunto de variables aleatorias discretas y  $\{x_1, \dots, x_n\}$  el conjunto de sus posibles realizaciones.

- Por ejemplo, si  $X_i$  es una variable binaria  $x_i$  puede ser 0 o 1.

- **Se denomina función de probabilidad conjunta a**

$$p(x_1, \dots, x_n) = p(X_1 = x_1, \dots, X_n = x_n)$$

- **Se denomina función de probabilidad marginal de la  $i$ -ésima variable mediante la fórmula:**

$$p(x_i) = p(X_i = x_i) = \sum_{x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n} p(x_1, \dots, x_n)$$

- **El conocimiento de la ocurrencia de un suceso puede modificar las probabilidades de otros sucesos.**

- Por ejemplo, la probabilidad de que un paciente tenga una enfermedad dada puede cambiar tras el conocimiento de los resultados de un análisis de sangre. Esto conduce al concepto de **probabilidad condicional**.

## La teoría de la Probabilidad

- **Medida de la probabilidad**

- Para medir la incertidumbre se parte de un conjunto  $S$  (**El espacio muestral**), en el que se incluyen todos los posibles resultados de un cierto experimento.

- Una vez definido este conjunto, el objetivo consiste en asignar a todo subconjunto  $S$  un número real que mida el grado de incertidumbre sobre su realización.

- Para obtener medidas con significado claro y práctico, se imponen ciertas propiedades intuitivas adicionales que definen una clase de medidas que se conocen como **medidas de probabilidad**.

## Probabilidad condicional

- **Definición 2. Probabilidad condicional.** Sean  $X$  e  $Y$  dos conjuntos disjuntos de variables tales que  $p(y) > 0$ . Entonces, la probabilidad condicional (función de probabilidad condicionada) de  $X$  dado  $Y=y$  viene dada por

$$p(X=x \mid Y=y) = p(x|y) = p(x,y)/p(y)$$

- Esta definición implica que la función de probabilidad conjunta de  $X$  e  $Y$  puede escribirse como

$$p(x,y) = p(y)p(x|y).$$

- Se obtiene un caso particular cuando  $X$  es una única variable e  $Y$  es un subconjunto de variables:

$$p(x_i \mid x_1, \dots, x_k) = p(x_i, x_1, \dots, x_k) / p(x_1, \dots, x_k)$$

## Dependencia e Independencia

- Definición 3. Independencia de dos variables.** Sean  $X$  e  $Y$  dos subconjuntos disjuntos del conjunto de variables aleatorias  $\{X_1, \dots, X_n\}$ . Entonces se dice que  $X$  es **independiente** de  $Y$  si y solamente si

$$p(x|y) = p(x),$$

para todos los valores posibles de  $x$  e  $y$  de  $X$  e  $Y$ ; en otro caso,  $X$  se dice **dependiente** de  $Y$ .

Nótese que al si  $x$  e  $y$  son valores posibles de  $X$  e  $Y$ , entonces  $p(x) > 0$  y  $p(y) > 0$ .

- Si  $X$  es independiente de  $Y$ , entonces nuestro conocimiento de  $Y$  no afecta nuestro conocimiento sobre  $X$ , es decir,  $Y$  no tienen información sobre  $X$ .
- Si  $X$  es independiente de  $Y$  entonces  $p(x,y) = p(x) p(y)$ .
- Una propiedad importante de la relación de independencia es su simetría:  
 $p(y|x) = p(x,y) / p(x) = p(x) p(y) / p(x) = p(y)$

## Ejemplo: variables

- Sea  $A$  una persona elegida al azar de la población.
  - Sin conocer si la persona es fumadora, la probabilidad de que se trate de una mujer es  $p(A=\text{mujer}) = 0.50$
  - Si se sabe que las persona es fumadora, esta probabilidad cambia de 0.50 a  $p(A=\text{mujer} | A = f) = 0.64$ .
- Por lo tanto, se tiene que  $p(A=\text{mujer} | A = f) \neq p(A = \text{mujer})$ ; por lo que las variables **Sexo** y **Fumador** son dependientes.
- ¿Estado Civil contiene información relevante sobre el Sexo?

## Independencia de variables

- Definición 4. Independencia de un conjunto de variables.** Las variables aleatorias  $\{X_1, \dots, X_n\}$  se dice que son **independientes si y sólo si**

$$p(x_1, \dots, x_m) = \prod_{i=1}^m p(x_i)$$

para todos los valores posibles  $x_1, \dots, x_m$  de  $X_1, \dots, X_m$ . En otro caso se dice que son dependientes.

- Si  $X_1, \dots, X_m$  son condicionalmente independientes dado otro subconjunto  $Y_1, \dots, Y_n$ , entonces

$$p(x_1, \dots, x_m | y_1, \dots, y_n) = \prod_{i=1}^m p(x_i | y_1, \dots, y_n)$$

- Una implicación importante de la **independencia** es que no es rentable obtener información sobre variables independientes, pues es **irrelevante**. Es decir, independencia significa irrelevancia.

## Ejemplo : Distribuciones de probabilidad

- Considérese la función de probabilidad conjunta de tres variables binarias:

x	y	z	p(x,y,z)
0	0	0	0.12
0	0	1	0.18
0	1	0	0.04
0	1	1	0.16
1	0	0	0.09
1	0	1	0.21
1	1	0	0.02
1	1	1	0.18

Í Función de probabilidad marginal de X:

$$p(X=0) = \sum_{y=0}^1 \sum_{z=0}^1 p(0,y,z) = 0.12+0.18+0.04+0.16 = 0.5$$

$$p(X=1) = \sum_{y=0}^1 \sum_{z=0}^1 p(1,y,z) = 0.09+0.21+0.02+0.18 = 0.5$$

Í Función de probabilidad conjunta de X e Y

$$p(X=0, Y=0) = \sum_{z=0}^1 p(0,0,z) = 0.12+0.18 = 0.3$$

$$p(X=0, Y=1) = \sum_{z=0}^1 p(0,1,z) = 0.04+0.16 = 0.2$$

$$p(X=1, Y=0) = \sum_{z=0}^1 p(1,0,z) = 0.09+0.21 = 0.3$$

$$p(X=1, Y=1) = \sum_{z=0}^1 p(1,1,z) = 0.18+0.02 = 0.2$$

## Ejemplo: variables

- Considérense las siguientes características de las personas de una población
  - Sexo = {hombre, mujer}
  - Fumador = {si (f), no ( $\neg$  f)}
  - Estado civil = {casado (c), no casado ( $\neg$  c)}
  - Embarazo = {si (e), no ( $\neg$  e)}
- Función de probabilidad conjunta

		h		m	
		f	$\neg$ f	f	$\neg$ f
c	e	0.00	0.00	0.01	0.05
	$\neg$ e	0.02	0.18	0.04	0.10
$\neg$ c	e	0.00	0.00	0.01	0.01
	$\neg$ e	0.07	0.23	0.10	0.18

- Por ejemplo, el 50% de las personas son mujeres, y el  
 $((0.01+0.04+0.01+0.1)/((0.01+0.04+0.01+0.1)+(0.00+0.02+0.00+0.07))) = 64\%$   
 de los fumadores son mujeres

## Dependencia e Independencia condicional

- Definición 5: dependencia e independencia condicional:** Sean  $X, Y, Z$  tres conjuntos disjuntos de variables, entonces  $X$  se dice condicionalmente independiente de  $Y$ , dado  $Z$ , si y sólo si  $p(x|z, y) = p(x|z)$  para todos los valores posibles de  $x, y, y, z$  de  $X, Y$  y  $Z$ ; En otro caso  $X$  e  $Y$  se dicen condicionalmente dependientes dado  $Z$ .
  - Cuando  $X$  e  $Y$  son condicionalmente independientes dado  $Z$ , se escribe  $I(X, Y|Z)$ , y se escribe  $D(X,Y|Z)$  si  $X$  e  $Y$  son condicionalmente dependientes de  $Z$ .
  - La definición de independencia condicional lleva en sí la idea de que una vez conocida  $Z$ , el conocimiento de  $Y$  no altera la probabilidad de  $X$ .

## Teorema de Bayes

### Teorema de Bayes


$$p(x_i | x_1, \dots, x_k) = \frac{p(x_i) p(x_1, \dots, x_k | x_i)}{\sum_{x_i} p(x_i) p(x_1, \dots, x_k | x_i)}$$

Supóngase que un paciente puede estar sano, o tiene una de m-1 enfermedades posibles ( $E_1, \dots, E_{m-1}$ ). Por simplicidad, sea E una variable aleatoria que puede tomar uno de m posibles valores  $\{e_1, \dots, e_m\}$ , donde  $e_m$  significa que el paciente está sano.

Supongase también que se tienen n síntomas ( $S_1, \dots, S_n$ ). Ahora dado que el paciente tiene un conjunto de síntomas ( $s_1, \dots, s_n$ ), se desea calcular la probabilidad de que el paciente tenga la enfermedad  $E_i$ . Aplicando el teorema de Bayes:

$$p(e_i | s_1, \dots, s_k) = \frac{p(e_i) p(s_1, \dots, s_k | e_i)}{\sum_{e_i} p(e_i) p(s_1, \dots, s_k | e_i)}$$

## Ejemplo : Adenocarcinoma gástrico



=> Pueden hacerse las siguientes afirmaciones:

- Probabilidad a priori: 440 de 1000 pacientes vomitan =>  $p(v) = 0.44$
- Verosimilitud: El 50% de los pacientes que tienen la enfermedad vomitan.  
 $p(v|g) = \text{card}(v|g)/\text{card}(g) = 350/750 = 0.5$   
 mientras que sólo el 30% de los paciente que no tienen la enfermedad vomitan  
 $p(v|\neg g) = \text{card}(v, \neg g)/\text{card}(\neg g) = 90/300 = 0.3$
- Verosimilitud: El 45% de los pacientes que tienen la enfermedad vomitan y pierden peso,  
 $p(v,p|g) = \text{card}(v,p,g)/\text{card}(g) = 315/750 = 0.45$   
 mientras que sólo el 12% de los que no tienen la enfermedad vomitan y pierden peso  
 $p(v,p|\neg g) = \text{card}(v,p, \neg g)/\text{card}(\neg g) = 35/300 = 0.12$

## Teorema de Bayes

$$p(e_i | s_1, \dots, s_k) = \frac{p(e_i) p(s_1, \dots, s_k | e_i)}{\sum_{e_i} p(e_i) p(s_1, \dots, s_k | e_i)}$$

- La probabilidad  $p(e_i)$  se llama **probabilidad marginal, inicial** o "a priori" de la enfermedad  $E = e_i$  puesto que puede ser obtenida antes de conocer los síntomas.
- La probabilidad  $p(e_i | s_1, \dots, s_k)$  es la **probabilidad posterior, condicional** o "a posteriori" de la enfermedad  $E = e_i$ , puesto que se calcula después de conocer los síntomas  $S_1 = s_1, \dots, S_k = s_k$ .
- La probabilidad  $p(s_1, \dots, s_k | e_i)$  se conoce por el nombre de verosimilitud de que un paciente con la enfermedad  $E = e_i$  tenga los síntomas  $S_1 = s_1, \dots, S_k = s_k$ .
- Se puede utilizar el teorema de Bayes para actualizar la probabilidad "a posteriori" usando ambas, la probabilidad "a priori" y la verosimilitud.

## Ejemplo : Adenocarcinoma gástrico

- Puesto que la probabilidad inicial de que el paciente tenga adenocarcinoma gástrico,  $p(g) = 0.7$ , no es suficientemente alta para hacer un diagnóstico (tomar una decisión ahora implica una probabilidad 0.3 de equivocarse), el doctor decide examinara al paciente para obtener **más información**:

- Supóngase que los resultados muestran que el paciente tiene los síntomas vómitos ( $V=v$ ) y pérdida de peso ( $P=p$ ). ¿Cuál es ahora la probabilidad de que el paciente tenga la enfermedad?

Tras observar que  $V=v$  la probabilidad a posteriori es


$$p(g|v) = \frac{p(g) p(v|g)}{p(g) p(v|g) + p(\neg g) p(v|\neg g)} = \frac{0.7 \times 0.5}{(0.7 \times 0.5) + (0.3 \times 0.3)} = 0.795$$

- Tras observar que  $V=v$  y  $P=p$  la probabilidad a posteriori es

$$p(g|v,p) = \frac{p(g) p(v,p|g)}{p(g) p(v,p|g) + p(\neg g) p(v,p|\neg g)} = \frac{0.7 \times 0.45}{(0.7 \times 0.45) + (0.3 \times 0.12)} = 0.9$$

## Ejemplo : Adenocarcinoma gástrico

- Un centro médico tienen una base de datos consistente en las historias clínicas de  $N = 1000$  pacientes.



- Hay 700 pacientes (región sombreada) que tienen la enfermedad adenocarcinoma gástrico (G), y 300 no la tienen.
- Tres síntomas: Dolor (D), pérdida de peso (P) y vómitos (V) están ligados a la enfermedad.
- Cuando un paciente nuevo llega a la consulta, hay una probabilidad  $700/1000 = 70\%$  de que el paciente tenga G.

## Ejemplo : Adenocarcinoma gástrico

- Nótese que cuando se aplica el teorema de Bayes sucesivamente, la probabilidad "a posteriori" calculada en una etapa dada es la misma que la probabilidad "a priori" en la siguiente.

- Por ejemplo, la probabilidad "a posteriori" que se ha calculado en el primer paso anterior, puede ser utilizada como probabilidad "a priori" en la siguiente:

$$p(g|v,p) = \frac{p(g|v) p(p|g,v)}{p(g|v) p(p|g,v) + p(\neg g|v) p(p|\neg g,v)}$$

$$= \frac{0.795 \times 0.9}{(0.795 \times 0.9) + (0.205 \times 0.389)} = 0.9$$

### Teorema de Bayes como clasificador

Simplificación del teorema

$$P(h/D) = \frac{P(D/h)P(h)}{P(D)}$$

- $P(h)$  : probabilidad a priori de la hipótesis  $h$
- $P(D)$ : probabilidad a priori de los datos de entrenamiento  $D$
- $P(h/D)$ : probabilidad de  $h$  dado  $D$
- $P(D/h)$ : probabilidad  $D$  dado  $h$

### Algoritmo de aprendizaje de la probabilidad máxima a posteriori MAP

- Para cada hipótesis de  $h \in H$ , calcule la probabilidad a posteriori

$$P(h/D) = \frac{P(D/h)P(h)}{P(D)}$$

- Escoja la hipótesis  $h_{MAP}$  de mayor probabilidad a posteriori:

$$h_{MAP} = \arg \max_{h \in H} P(h/D)$$

### Elección de hipótesis

- Generalmente se desea la hipótesis mas probable observada en los datos de entrenamiento
- Hipótesis de mayor probabilidad a posteriori

$$\begin{aligned} h_{MAP} &= \arg \max_{h \in H} P(h/D) \\ &= \arg \max_{h \in H} \frac{P(D/h)P(h)}{P(D)} \\ &= \arg \max_{h \in H} P(D/h)P(h) \end{aligned}$$

- Hipótesis de máxima verosimilitud

$$h_{ML} = \arg \max_{h_i \in H} P(D/h_i)$$

### Clasificación mas probable de una nueva instancia

- Dada una nueva instancia  $x$ , cual es su clasificación mas probable?

- $h_{MAP}(x)$  no es la clasificación mas probable

- Considere

- $P(h_1/D) = 0.4$ ,  $P(h_2/D) = 0.3$  e  $P(h_3/D) = 0.3$
- Dada una nueva instancia de  $x$  suponga que
- $h_1(x) = +$ ,  $h_2(x) = -$  y  $h_3(x) = -$
- La clasificación mas probable de  $x$  es -

### Aplicación del Teorema de Bayes

- Sea

- $M$  = enfermedad meningitis
- $S$  = Dolor de cabeza

- Un doctor sabe

- $P(S/M) = 0.5$
- $P(M) = 1 / 50000$
- $P(S) = 1 / 20$

$$P(M/S) = \frac{P(S/M)P(M)}{P(S)}$$

$$= \frac{0.5 * (1/50000)}{1/20} = 0.0002$$

- La probabilidad de una persona tener meningitis dado que ella está con dolor de cabeza es 0,0002% o 1 en 5000.

### Clasificador Bayesiano optimo

- Un nuevo ejemplo puede ser clasificado como  $v_j \in V$ , la probabilidad de clasificación correcta  $v_j$

$$P(v_j/D) = \sum_{h_i \in H} P(v_j/h_i)P(h_i/D)$$

Clasificación bayesiana optima

$$\arg \max_{v_j \in V} \sum_{h_i \in H} P(v_j/h_i)P(h_i/D)$$

## Ejemplo clasificador Bayesiano

- Dado

- $P(h_1/D) = 0.4$ ,  $P(-/h_1) = 0$ ,  $P(+/h_1) = 1$
- $P(h_2/D) = 0.3$ ,  $P(-/h_1) = 1$ ,  $P(+/h_1) = 0$
- $P(h_3/D) = 0.3$ ,  $P(-/h_3) = 1$ ,  $P(+/h_1) = 0$

- Por lo tanto

$$\sum_{h_i \in H} P(+ / h_i) P(h_i / D) = 0.4 \quad \sum_{h_i \in H} P(- / h_i) P(h_i / D) = 0.6$$

$$\arg \max_{v_j \in V} \sum_{h_i \in H} P(v_j / h_i) P(h_i / D) = -$$

## Clasificador Bayesiano ingenuo

- Una función de clasificación  $f: X \rightarrow V$  donde cada instancia en  $X$  es descrita por los atributos  $\{a_1, \dots, a_n\}$

$$\begin{aligned} v_{MAP} &= \arg \max_{v_j \in V} P(v_j / a_1, \dots, a_n) \\ &= \arg \max_{v_j \in V} \frac{P(a_1, \dots, a_n / v_j) P(v_j)}{P(a_1, \dots, a_n)} \\ \text{Suposición ingenua} &= \arg \max_{v_j \in V} P(a_1, \dots, a_n / v_j) P(v_j) \end{aligned}$$

- Clasificador bayesiano ingenuo

$$\begin{aligned} P(a_1, \dots, a_n / v_j) &= \prod_i P(a_i / v_j) \\ v_{NB} &= \arg \max_{v_j \in V} P(v_j) \prod_i P(a_i / v_j) \end{aligned}$$

## Ejemplo

Día	Tiempo	Temp.	Humed.	Viento	Jugar
D1	Sol	Caliente	Alta	Debil	No
D2	Sol	Caliente	Alta	Fuerte	No
D3	Cubierto	Caliente	Alta	Debil	Si
D4	Lluvia	Normal	Alta	Debil	Si
D5	Lluvia	Frio	Normal	Debil	No
D6	Lluvia	Frio	Normal	Fuerte	No
D7	Cubierto	Frio	Normal	Fuerte	Si
D8	Sol	Normal	Alta	Debil	No
D9	Sol	Frio	Normal	Debil	Si
D10	Lluvia	Normal	Normal	Debil	Si
D11	Sol	Frio	Alta	Fuerte	?

- $P(Si) = 5/10 = 0.5$
- $P(No) = 5/10 = 0.5$
- $P(Sol/Si) = 1/5 = 0.2$
- $P(Sol/No) = 3/5 = 0.6$
- $P(Frio/Si) = 2/5 = 0.4$
- $P(Frio/No) = 2/5 = 0.4$
- $P(Alta/Si) = 2/5 = 0.4$
- $P(Alta/No) = 3/5 = 0.6$
- $P(Fuerte/Si) = 1/5 = 0.2$
- $P(Fuerte/No) = 2/5 = 0.4$
- $P(Si)P(Sol/Si)P(Frio/Si)$
- $P(Alta/Sm)P(Fuerte/Si) = 0.0032$
- $P(No)P(Sol/No)P(Frio/No)$
- $P(Alta/No)P(Fuerte/No) = 0.0288$
- $\Rightarrow \text{Jogar\_Tenis}(D11) = \text{No}$